Talend Open Studio e Python

Data Mart
DMOIs

SUMÁRIO

1.0. Ferramenta Talend

Talend, mais precisamente, Talend Open Studio é uma plataforma (SaS) desenvolvida em Java que fornece ferramentas para integração e gerenciamento de dados, a chave principal é para o processo ETL, com esta solução é possível conectar dados de várias fontes em diferentes sistemas. Ele suporta integração de dados em lote e em tempo real.

Esta ferramenta é muito fácil de implementar e começar a desenvolver, Talend fornece um ambiente de desenvolvimento gráfico que permite aos usuários projetar e implementar integração de dados e/ou ETL.

A ferramenta é dividida em "componentes" e estes componentes possuem inúmeras propriedades, como componentes de conexão via jdbc e clouds, transformações de dados, mapeamentos, notas, etc,

O Talend possui componentes de conexões com as clouds, é possível usar esta ferramenta para integração com as três principais provedoras, isso permite uma ampla gama de outras atividades que a ferramenta possibilita a ser desenvolvida, como migração de dados para a nuvem.

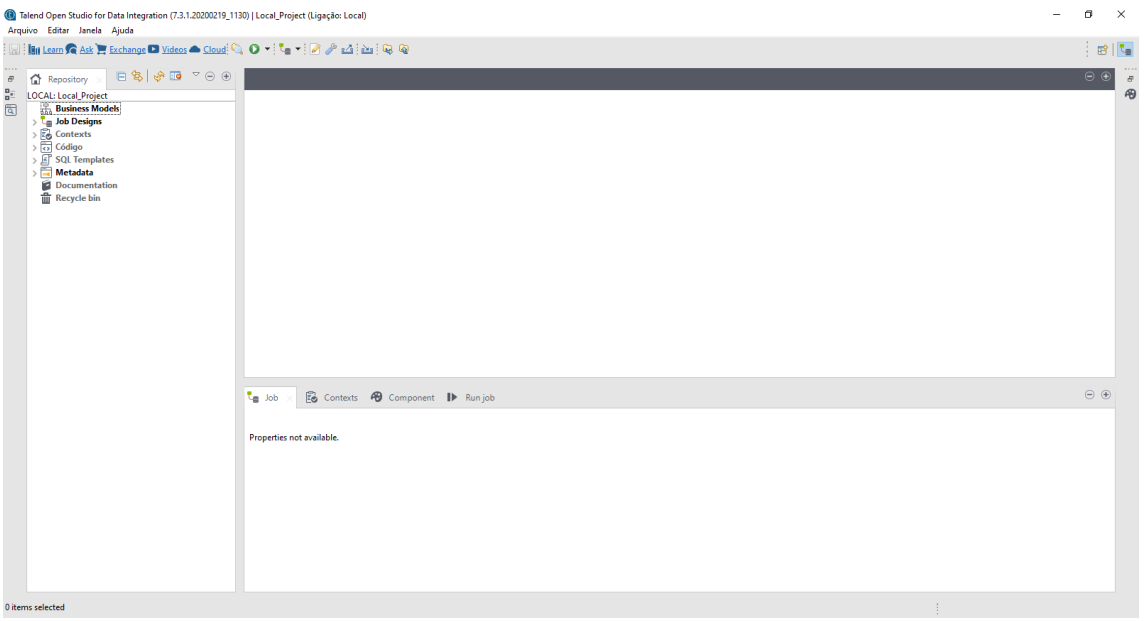

Interface do Talend no Windows 10.

2.0. DMOLS

A DMOls é um simples projeto de modelagem de dados de conceitos Star Schema de um Data Mart, a ideia é apenas explorar a ferramenta e suas funcionalidades com a sua analogia desenvolvida em puramente em Python.

Os dados utilizados foram do marketplace olist, disponível neste link:
https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Após isso, estes csv do Kaggle da plataforma “Olist” foram migrados a dois bancos de dados diferentes, um banco MySQL e um banco PostgreSQL para simular dois bancos OLTP, ou duas fontes diferentes, os respectivos foram levantados com a ajuda do docker. E para simular a “Dw” ou em outras palavras o destino das integrações e do processo de ETL foi utilizado o banco de dados SQL Server que foi levantado via docker também.

Foi utilizado dois bancos porque nem sempre existem apenas uma fonte de dados no dia a dia, assim os dados dos bancos se complementam para as análises.

2.1. DMOLS TALEND E PYTHON ESTRUTURA

Para a versão do python foi desenvolvido um ambiente com poetry e as respectivas dependências que estão na descrição do repositório, a partir disso foi planejado um simples sistema onde existem consultas em arquivos SQL que precisam ser lidos e executadas no processo, similar ao Talend, mas no Talend escreve-se as consultas dentro da própria ferramenta em seus componentes de execuções.

Para a primeira etapa da versão do Python quanto da versão do Talend, foi definir a arquitetura inicial de como iria se comportar as pastas e os arquivos do projeto, para o Talend e o Python utilizei a mesma lógica, existe um script python chamado main.py e um job em Talend chamado MAIN, que é responsável por executar os respectivos subprocessos: run_staggings.py em Python e (RUN_STAGGING job em Talend) e também run_schemas.py em Python e (RUN_SCHEMAS job em Talend), esta é a arquitetura inicial dos processos.

Cada uma das duas funções / métodos ou Jobs representam a carga das stages e das dimensões e fatos para montar o Data Mart dentro da DW.

As Stages nada mais são que o dado da fonte já carregado na Dw em um formato tabular (pois podem ser outras fontes como API) já adequados para serem modelados nas dimensões e fatos.

As Dimensões são as características modeladas em algum Fato, por exemplo fato “venda”, a venda que ocorreu possui uma determinada característica que pode ser o cliente, e este cliente tem seus atributos como nome, cpf, portanto F_Venda e D_Cliente comportar uma modelagem.

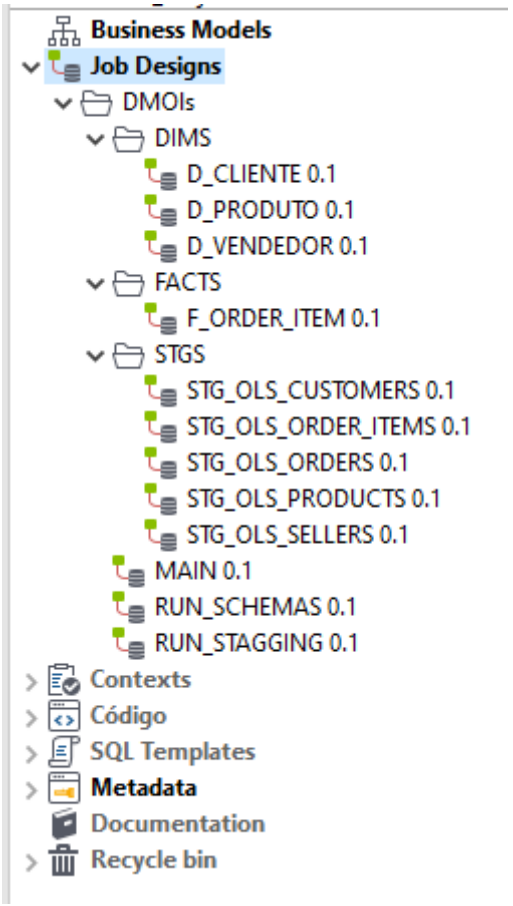

Para o Talend, como a consulta em sql a ser executada pode ser armazenada dentro dos componentes, então cada pasta possui o nome do processo em seus respectivos Jobs que serão executados nos (RUN_STAGGING e RUN_SCHEMAS) e cada Job deste possui uma consulta a ser realizada nos bancos de dados MySQL, PostgreSQL e SQL Server, esta é a estrutura de Jobs do Talend que escolhi.

Para a versão do Python é quase a mesma coisa, exceto que existe mais processos que irão coletar as query em formato “.sql” de alguma determinada pasta, e todo esse processamento está abstraído e é realizado dentro das classes (RunStagging e RunSchemas respectivamente), basta instanciar a classe e rodar os métodos, essa analogia final é a mesma do Talend, basta chamar um Job então é executado tudo que tem dentro dele.

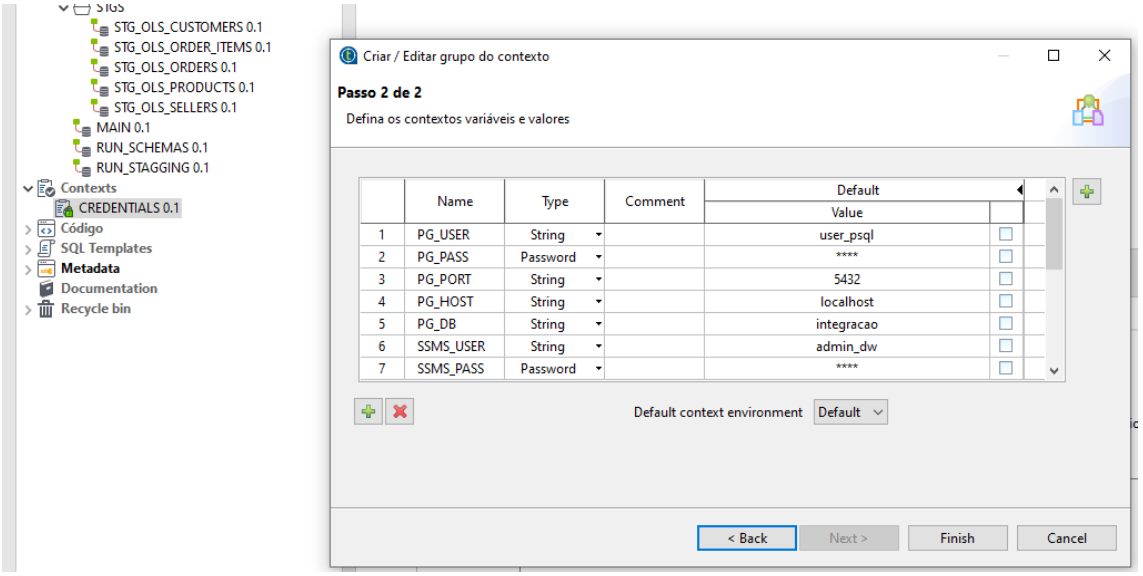

Já para as credenciais no Python fica dentro da pasta utils e no Talend no bloco “Contexts”.

2.2. DMOLS STAGGINGS

Para a carga das stages, a versão do python foi bem trabalhosa dado todas as validações e os processos assíncronos desenvolvidos, para a versão do Talend foi bem mais simples podendo entregar valor rapidamente para o projeto.

Levando em conta a "Stage Ols Customers", a primeira coisa é criar o schema no Sql Server chamado "StgOls", este schema do Sql Server vai ser responsável apenas por armazenar as stages do projeto.

Após isso, para a versão do Talend basta utilizar o componente de Input que é a conexão com o banco e a execução de uma query onde os dados serão propagados a partir de uma saída principal (chamada de fluxo "main"), e a partir disso, propaga-se a saída para um componente chamado TMap, que nada mais é que a etapa de fazer alguma eventual transformação, e por fim, o Output é as consultas de insert/update em algum lugar.

O fluxo geral está representado na imagem abaixo, note que o PreJob e PostJob são apenas para o mapeamento de Logs, igual o "print" do python que utilizei.

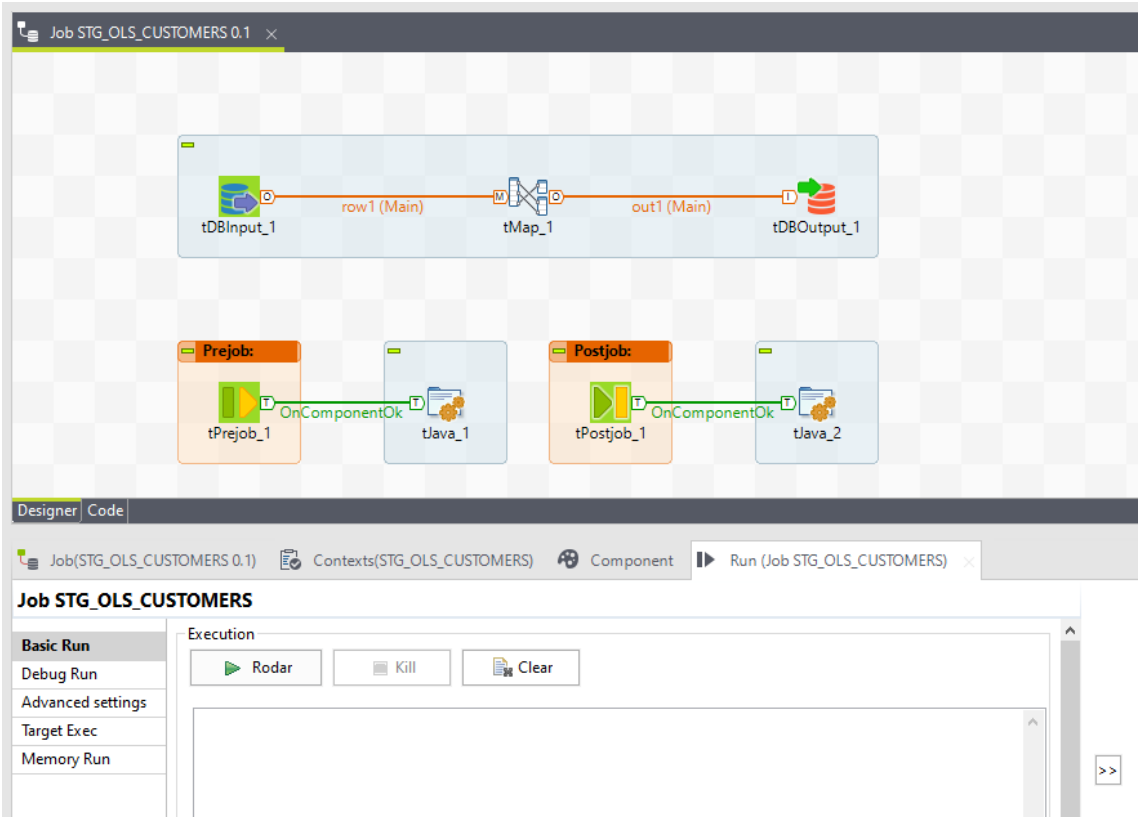

Esta da imagem é o fluxo principal, dos dados de uma Stage.

Fazendo as analogias com a versão do Python, o input é a consulta realizada com a classe Database, a parte do TMap é justamente a transformação e a criação da Data de

Processamento e o Output é a carga via método to_sql da classe DataFrame onde a carga vai acontecer abstraído no método to_sql..

O Componente Input do Talend recebe alguns parâmetros importantes, como as credenciais e o select com os dados que vão ser propagados no fluxo main, considere na imagem abaixo o fluxo agora para a Stage Ols Sellers que vai ser executada no banco MySQL agora.

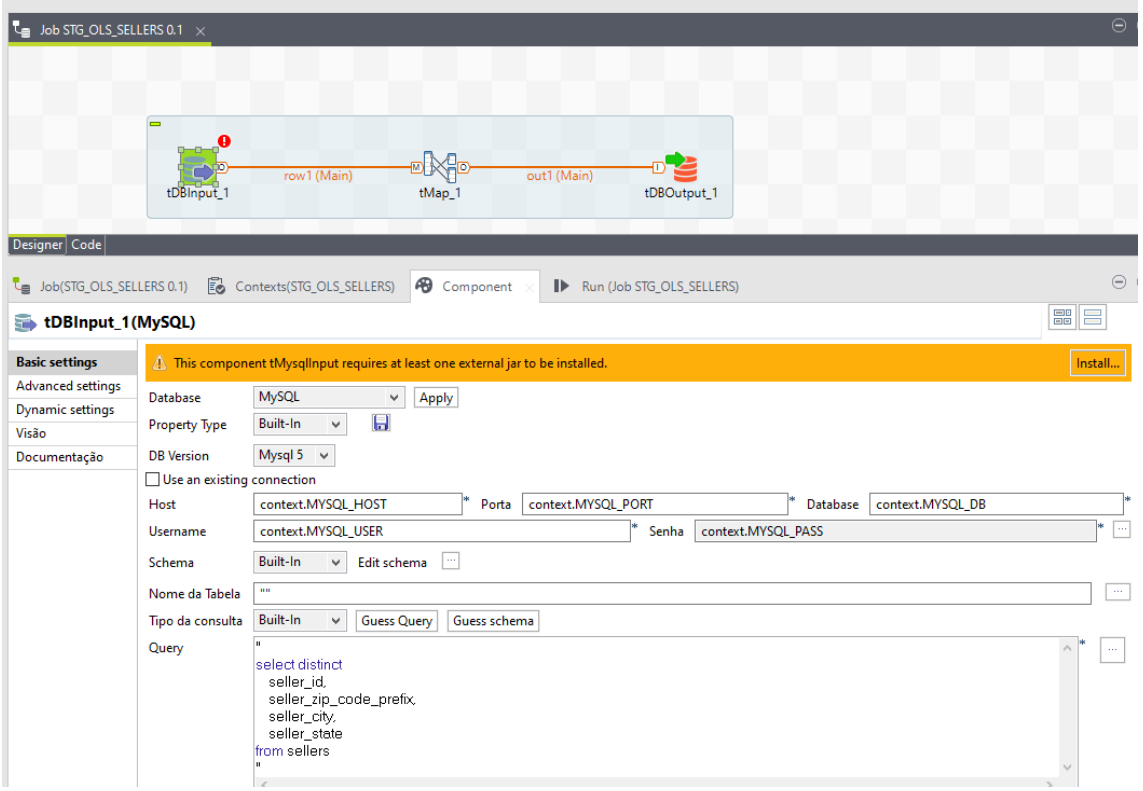

Neste caso, existem alguns parâmetros de conexões que estão nas variáveis context que foi definido anteriormente e a query em formato string (por isso os aspas) a ser executada e propaganda pelo fluxo “main” como indica a linha laranja com a setinha e o “M” dentro.

Repare que para o MySQL, é necessário instalar uma classe java (arquivo java) que vai ser responsável pela conexão com o banco de dados, para isso é só clicar em install e o próprio Talend vai ser responsável por coletar a versão da classe correta para a versão do conector do banco selecionada no dropbox chamado DB Version.

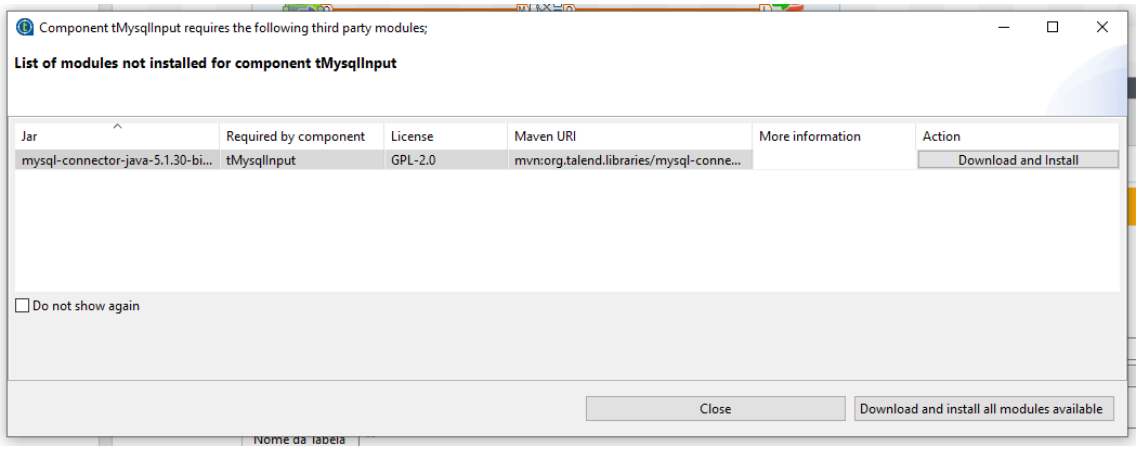

Fazendo as analogias com a versão Python, todo esse processamento de ler o arquivo com a consulta sql e coletar a conexão com o banco já é abstraído dentro das classes.

Agora, já dentro do TMap, é apenas propagado os dados do fluxo main e incluído um código em java que irá gerar a data e hora de quando o Job foi executado, este mesmo já estão na parte do Python também abstraídos dentro da classe.

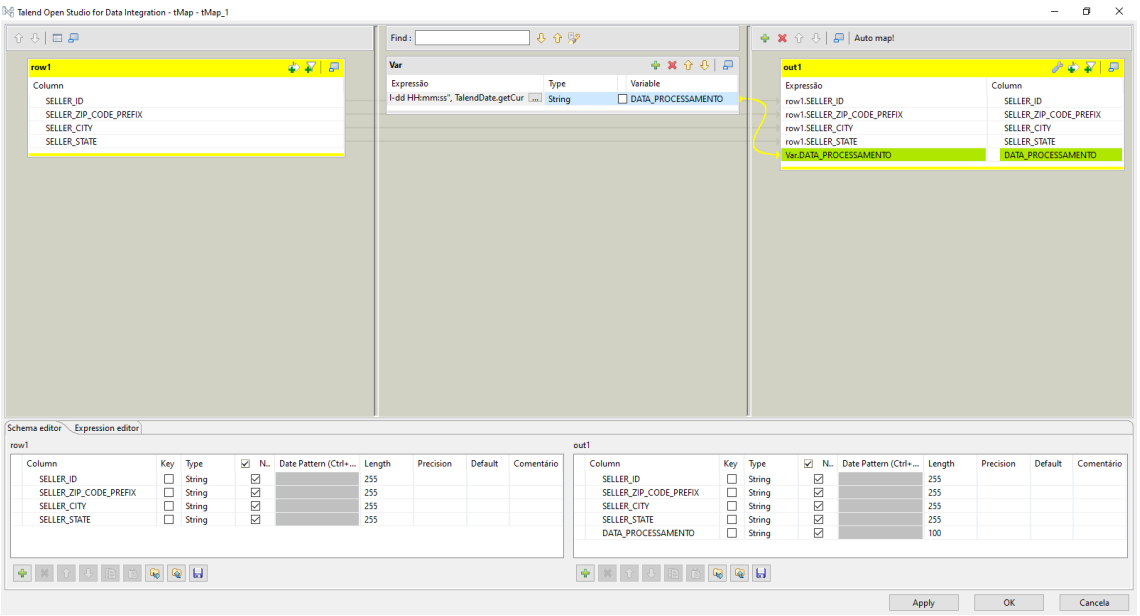

Fiz dessa forma pois, como os dados da stage são gerados na hora que o job foi executado, devemos limpar a stage novamente no destino, e sem a data de processamento não conseguimos ver na Dw se a stage foi executada ou não, assim na tabela final da stage existe mais uma coluna chamada DATA_PROCESSAMENTO responsável por indicar a data e horas que a tabela foi carregada, se o processo roda de hora em hora, espero que a cada gora que visualizar a tabela, sejam dados novos e para verificar isso basta visualizar esta coluna.

Tanto na versão Talend quanto na versão de Python é deletado a tabela stage e criada uma novamente do zero com os dados coletados da fonte como está representado no output do Job em Talend na imagem abaixo.

Define-se o nome da tabela, schemas e as credenciais, existem muitas outras opções interessantes a serem exploradas como “Die on Error” que irá parar o processo de ETL caso o script apresenta algum erro, a mesma solução foi desenvolvida diferente em python com um decorador responsável por um retry, caso não der certo mesmo com o retry a coleta da stage, então essa stage vai ser seguida no fluxo e o pipeline não vai quebrar, e na hora da inserção essa stage que deu problema não vai ser executada.

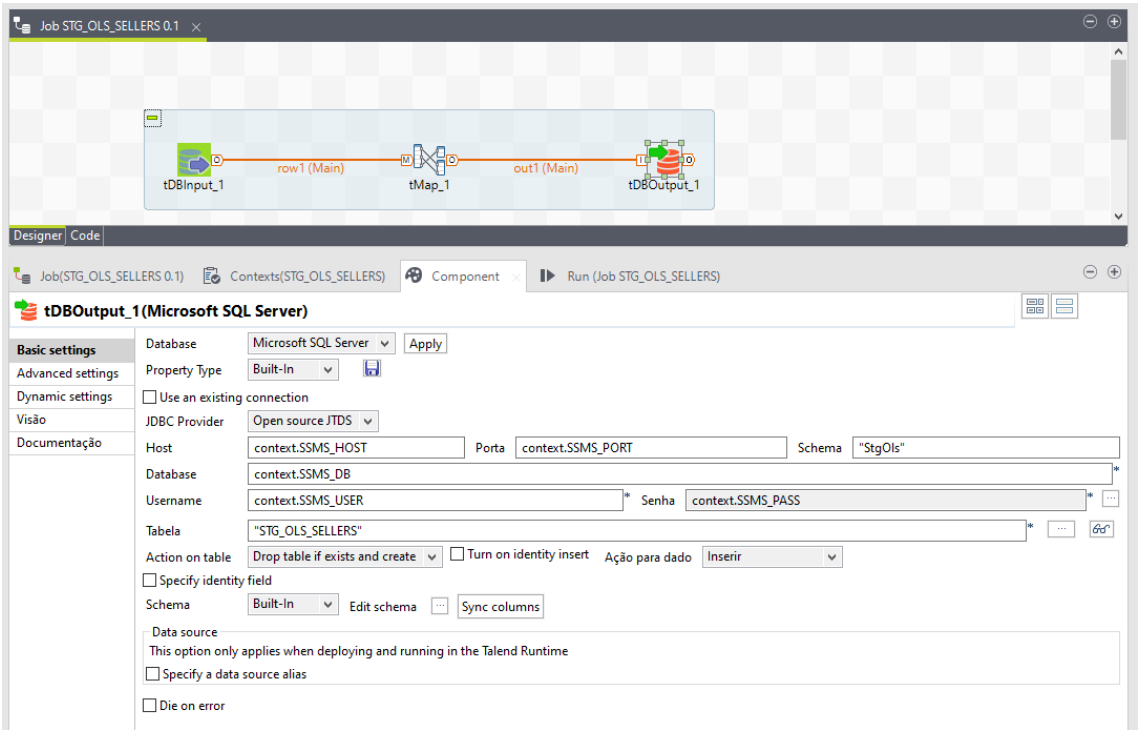

E, por fim, é deletado a tabela a cada vez que o Talend ou o Python são executados.

Existe mais um detalhe, na versão do Talend, todos os tipos de dados das colunas são no formato varchar(255), assim pelo menos caso de problema de conversão de tipo em algum momento do ETL as stages já estão previamente carregadas.

Seguindo esta mesma ideia, é gerado um Job específico com todas as stages, esse job é responsável por executar todas as stages em sequência e não em async igual a versão do Python, basta executar este Job e todas as stages são iniciadas (Job Run_Staggings do Talend).

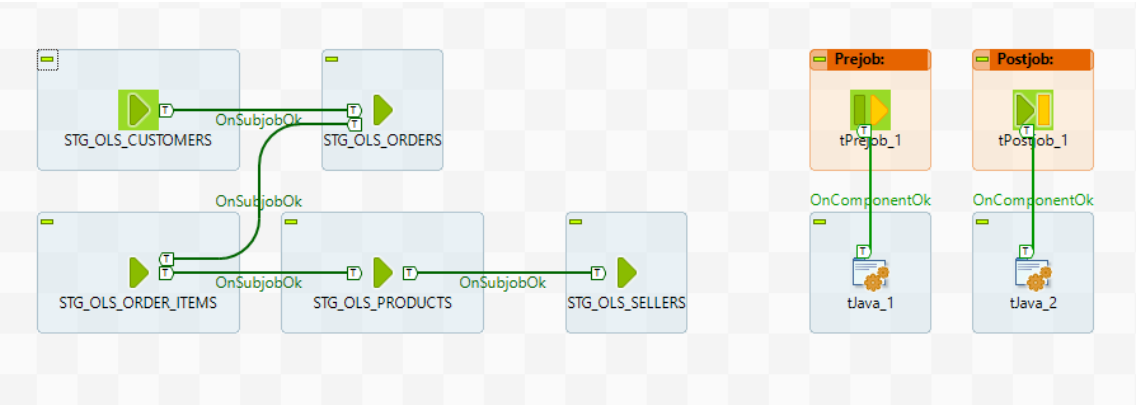

As stages já foram configuradas, basta executar / chamar elas no main, igual fiz no arquivo main.py da versão de Python, só que para o Talend seria um Job novo chamado MAIN, similar a algo assim:

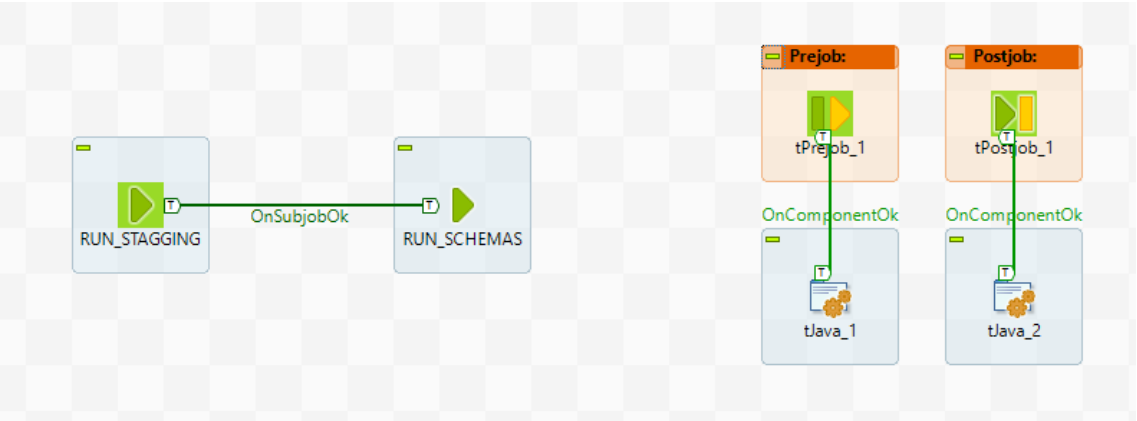

Nesse caso, só existirá a RUN_STAGGING seguindo o texto, precisa-se criar agora as modelagens das dimensões e fatos.

2.3. DMOLS SCHEMAS

Essa é a etapa de carga das dimensões e das fatos, essa parte é bem simples também, só que com alguns truques, as linhas (os dados) das dimensões e fatos devem ser atualizados ou inseridos,exceto algumas exceções como fatos que são limpas completamente e carregadas do zero e tabelas que são incrementais apenas, mas na maioria das vezes, principalmente paraas dimensões elas nunca devem ser deletadas pois é possível perder a referência do SK que vai ser citado ao decorrer do texto, essa etapa precisa-se definir em consultas sql de inserção ou atualização para a versão do Python, para a versão do Talend estas já estão abstraídas dentro dos componentes SCD.

Lembrando que agora é utilizado as tabelas stages para montar as tabelas dimensões e fatos, estas tabelas já estão no schema StgOls dentro do destino.

Neste caso, para o Talend, apenas utiliza o select dentro do componente de input que vai ser propagado ao longo do fluxo main, em vez de utilizar o componente de TMap, na imagem é utilizado um componente de casting para transformar os tipos de dados antes de salvar no banco SQL Server.

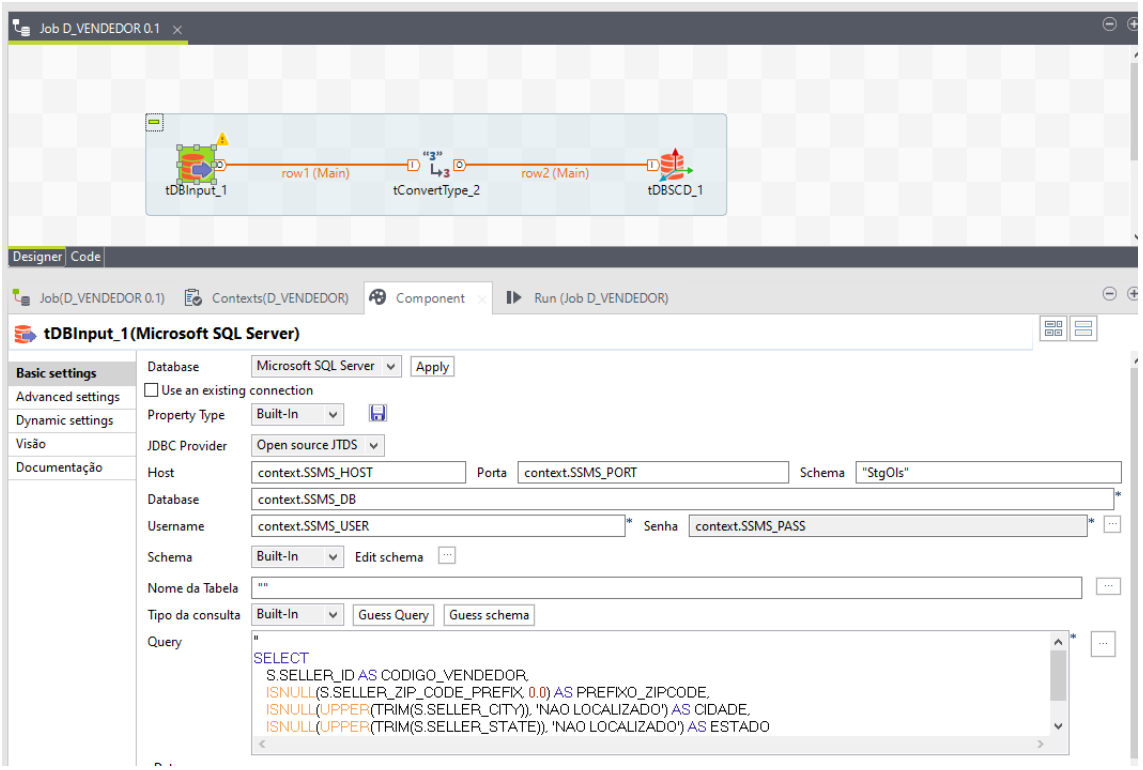

Para este caso, tanto o Schema quanto a tabela já devem estar criadas dentro do banco de dados com os seus respectivos index também, igual está na pasta de create_tables dentro da pasta sql no repositório do github.

Para a versão do Python, primeiro é executado o Insert e após isso o Update em duas consultas separadas e não no mesmo fluxo como o Talend, neste caso o Talend já faz essa tratativa para você.

Como citei, a tabela não vai ser deletada e sim inserido dados novos dado uma chave de verificação “id” ou atualizado os mesmos dados com este mesmo “id”.

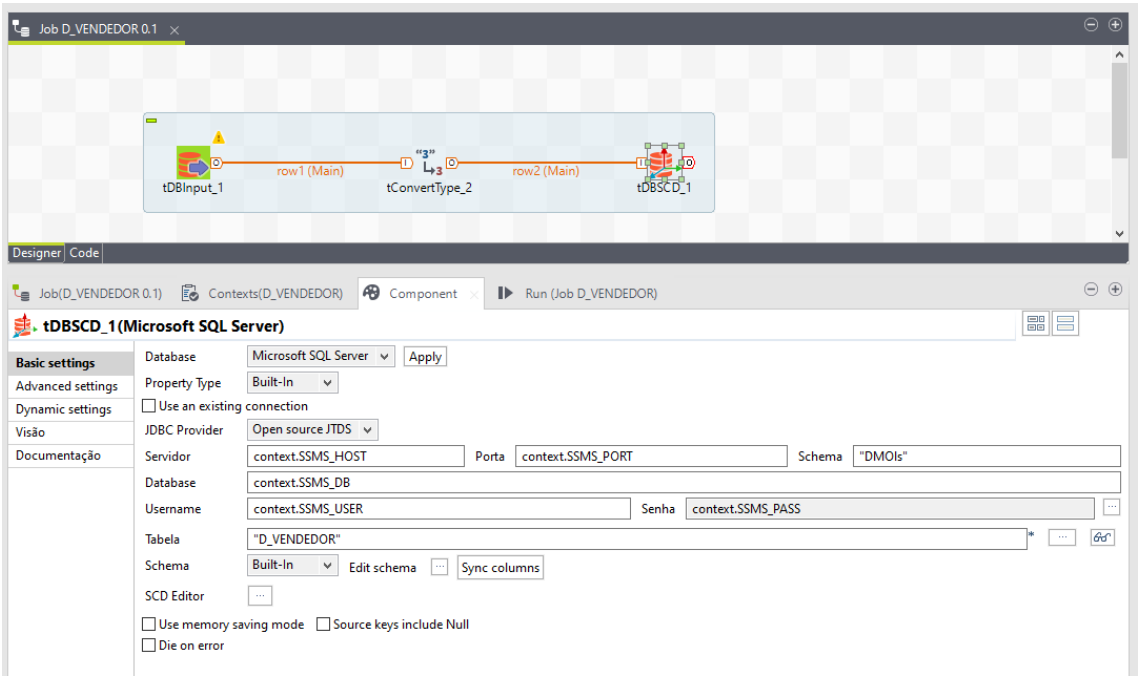

O componente que utilizei foi o SCD e também ele recebe alguns parâmetros.

A Source Key é a chave de atualização da tabela, o Surrogate Keys é como se fosse o “id” na modelagem dimensional da dimensão ou fato que é utilizada nas referências de dimensões ou fatos no modelo star schema ou snowflake schema.

E nas colunas Type 0..3 são os tipos da dimensão, neste caso, é apenas uma tabela que vai ser de referência de vendedores, então vai ser apenas inserido coisa nova ou atualizado às linhas já existentes desta tabela chamada DMOls.D_VENDEDOR pela chave CODIGO_VENDEDOR como está na imagem abaixo.

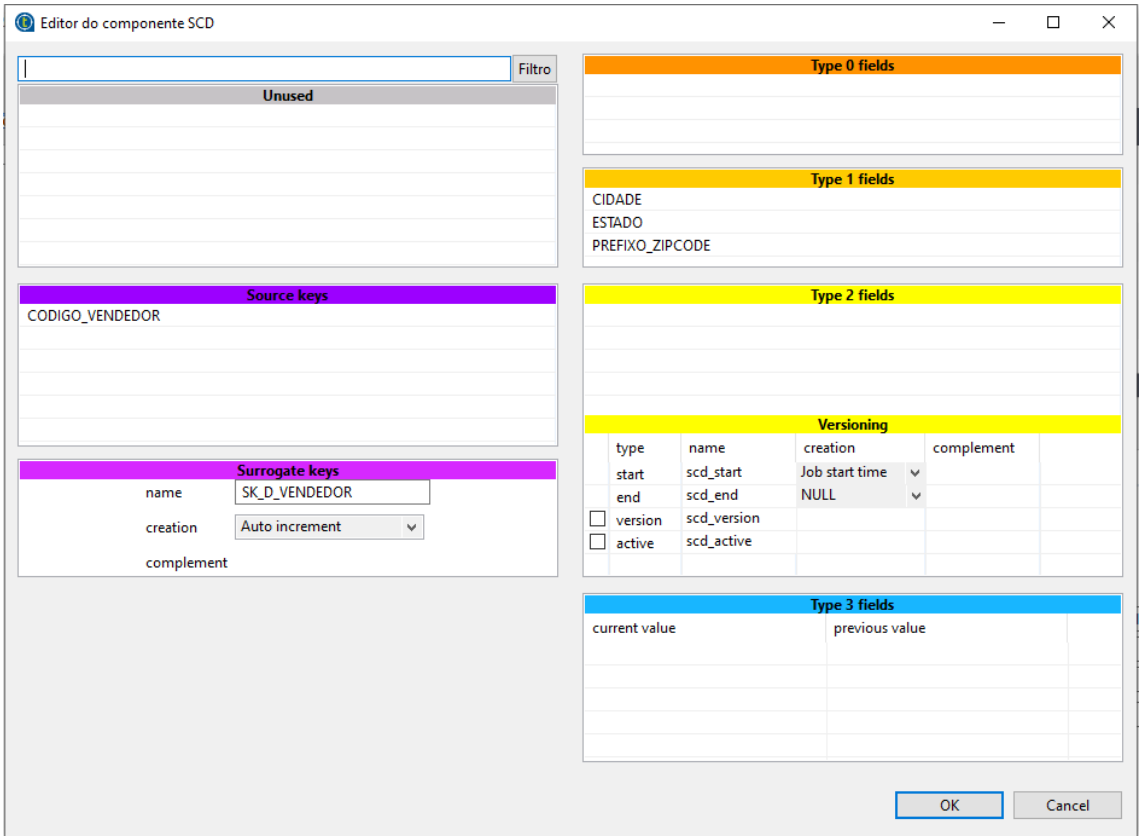

Toda esta lógica é criada por consultas sql de insert ou update na versão do Python.

Por fim, basta criar as demais dimensões e incluir elas no job RUN_SCHEMAS, finalizando as stages e a modelagem.

No caso do Python e também do Talend, coloquei no mesmo “Job” / classe, assim fica correto a analogia das duas ferramentas para fazer o mesmo processo de ETL, pois a versão do python irá carregar os selects de dimensões e executar eles e após isso ja executar em seguida as consultas das fatos, que seguem a mesma analogia do Talend apresentado na imagem abaixo.

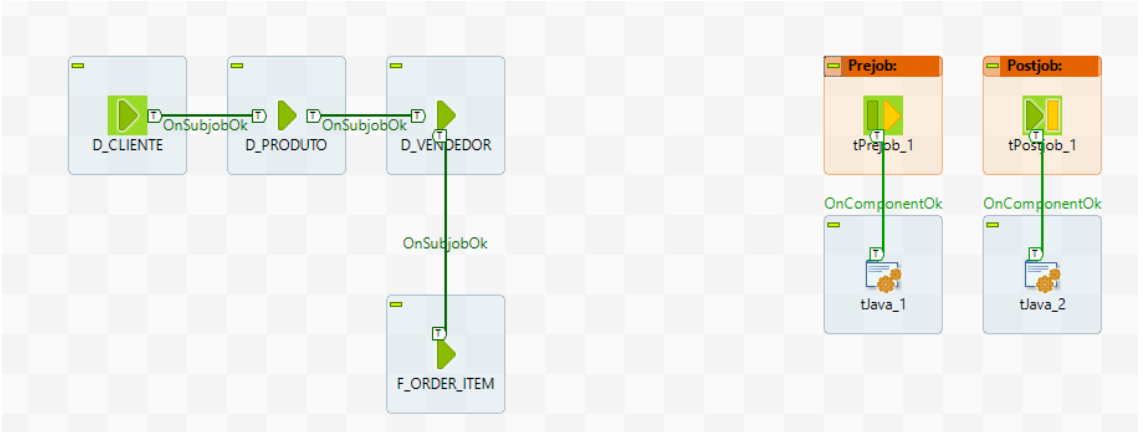

Para a Fato, utilizei a mesma arquitetura das stages, apenas mudando o Output para atualização e inserção ao invés da deleção como é feita nas stages.

Para o Input é a mesma configuração das stages, mas não coletando da fonte e sim da Dw, pois os dados já estão no schema **StgOls** e já foram previamente **tratados**.

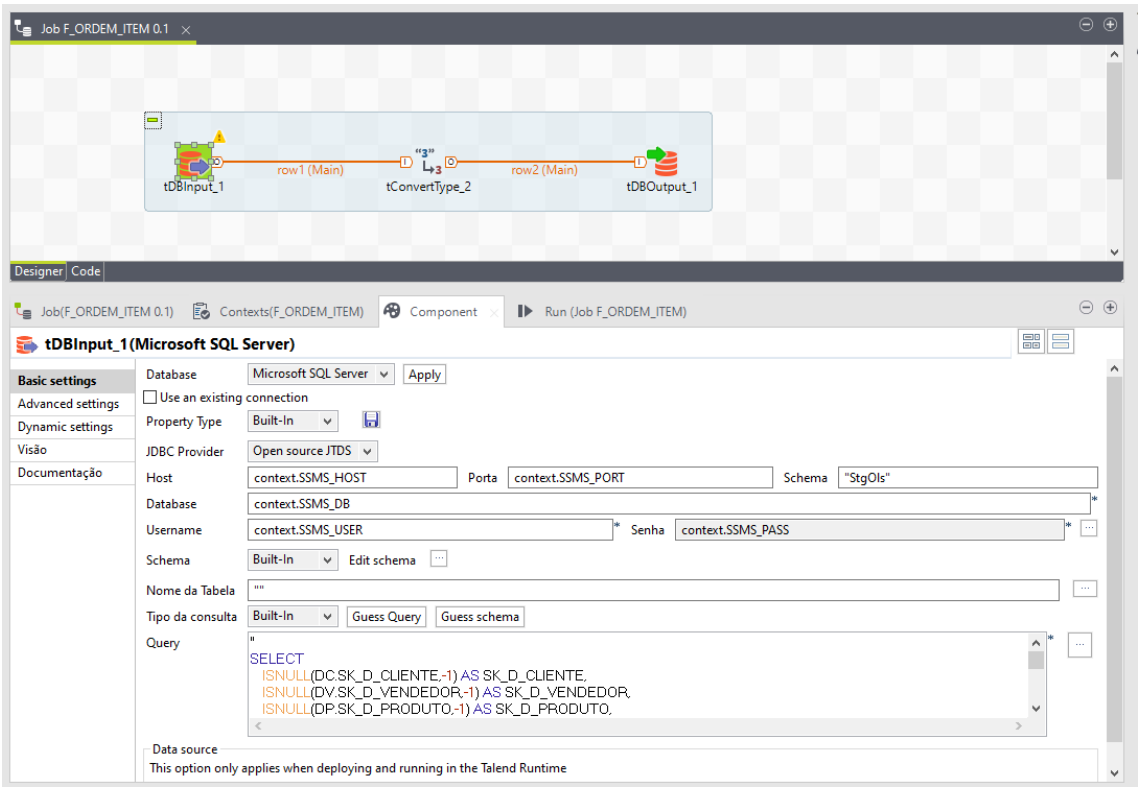

A única atualização neste caso é o output, nas opções Action on Table e Action on Data (o meu está em Português pela metade).

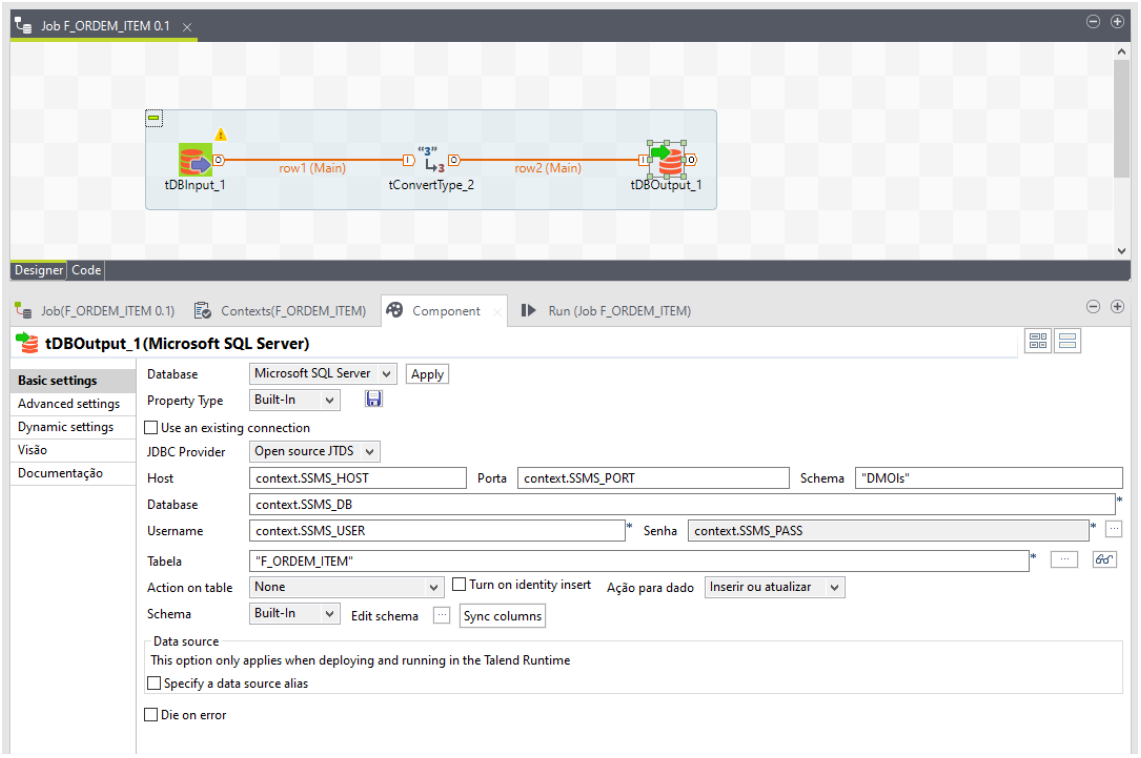

A ação é inserir ou atualizar, sem deletar a tabela, apenas inserir novas linhas ou atualizar baseado em alguma chave de verificação, para definir as chaves de atualização é nas opções avançadas do componente onde todas são possíveis de serem inseridas na tabela mas a coluna CODIGO_ORDEM é a chave "id" em outras palavras é a coluna de atualização das linhas da fato que vai garantir que vai ser inserido coisa nova ou atualizado linhas já existentes.

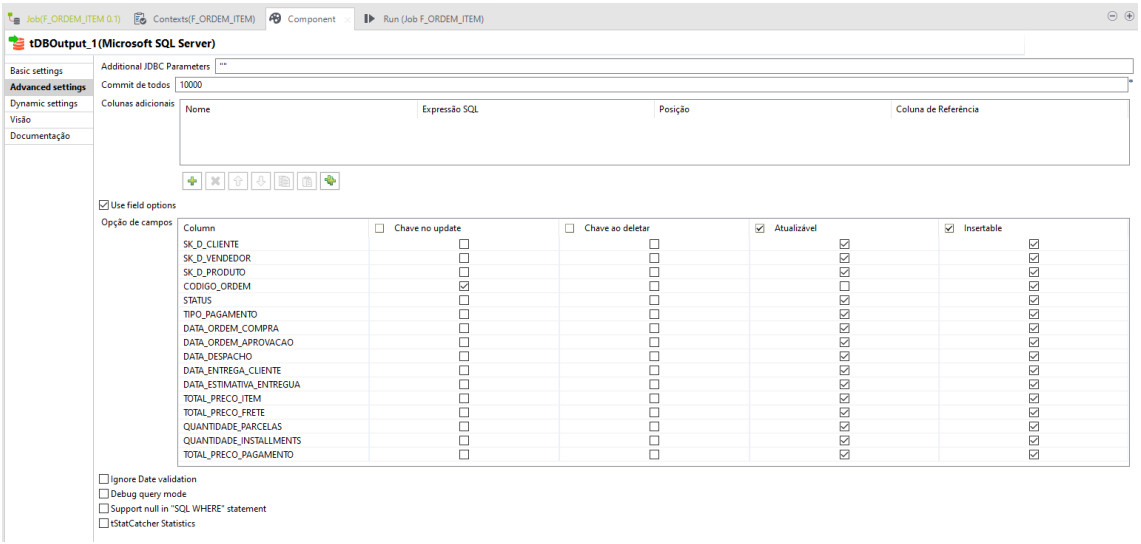

Por exemplo, o acompanhamento de uma venda, se a coluna "venda_status" está em "processamento" e foi salva na fato com este status, "logo logo" este mesmo status para

esta mesma venda pode ser atualizada, para venda concluída ou distratada ou em análise, etc, a linha vai sofrer atualização, e portanto deve ser atualizada na fato.

2.4. DMOLS EXECUÇÃO DO ETL

Para finalizar, basta executar o Job main ou o script main.py, ambos irão executar o ETL do projeto DMOls se tudo estiver devidamente configurado como as bases de dados.

Para gerar um script a ser executado sem precisar abrir o Talend e executar manualmente, deve-se seguir alguns passos.

Para a versão do Talend, o primeiro é a atualização dos “poms” do java, a primeira coisa a se fazer é fechar todos os Jobs abertos para evitar erros, e após isso seguir o passo a passo das imagens abaixo.

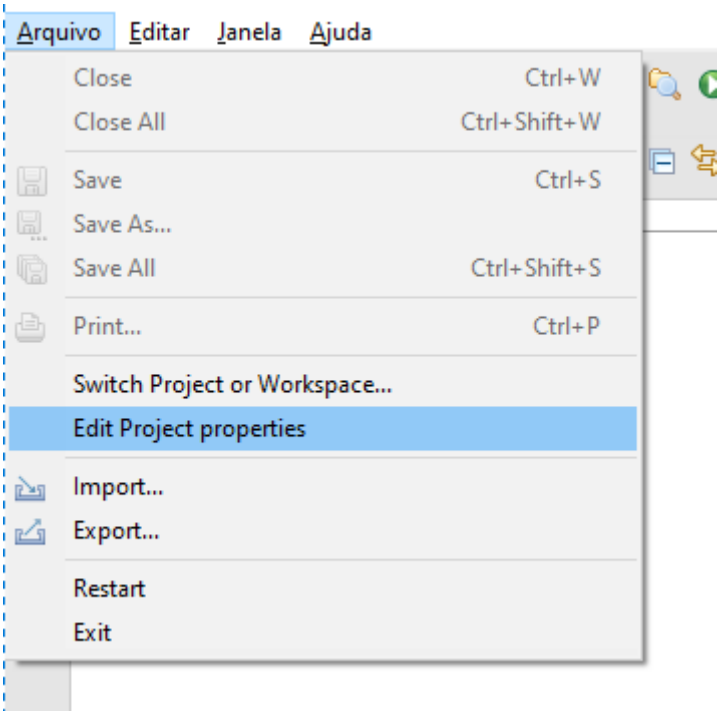

E navegar até a opção “Project” e por fim **Apply and Close**.

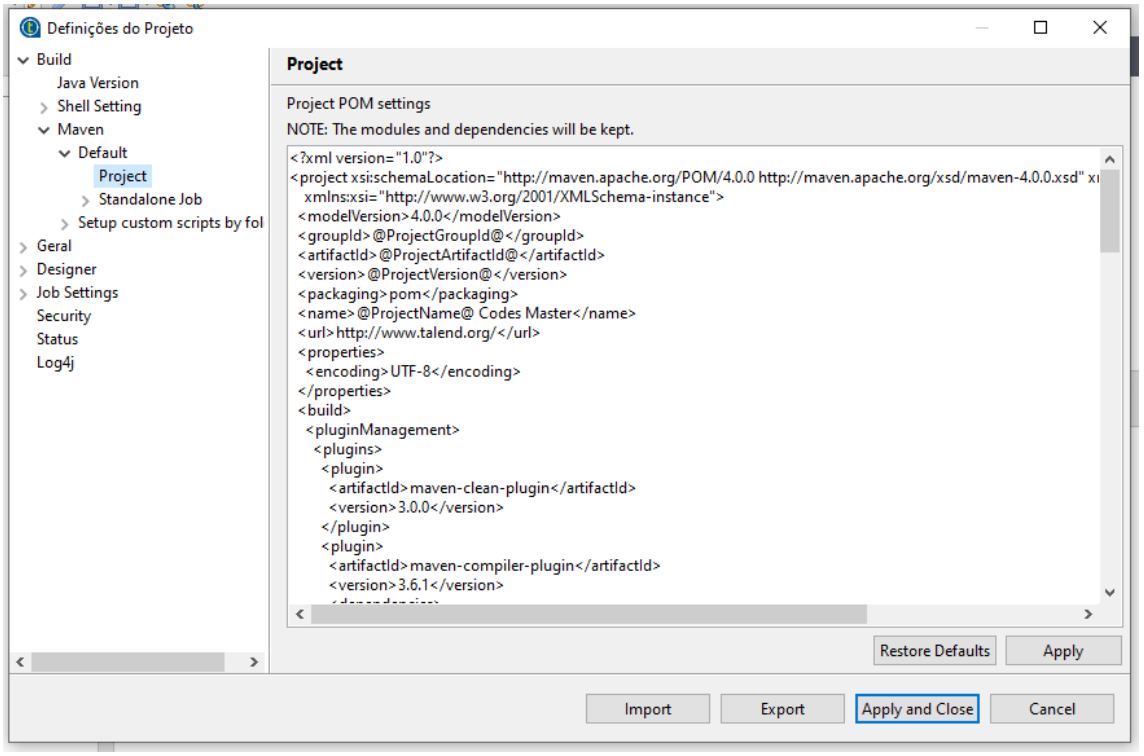

Após isso, como toda a lógica está no main, você pode gerar os scripts para serem executados seguindo este passo a passo.

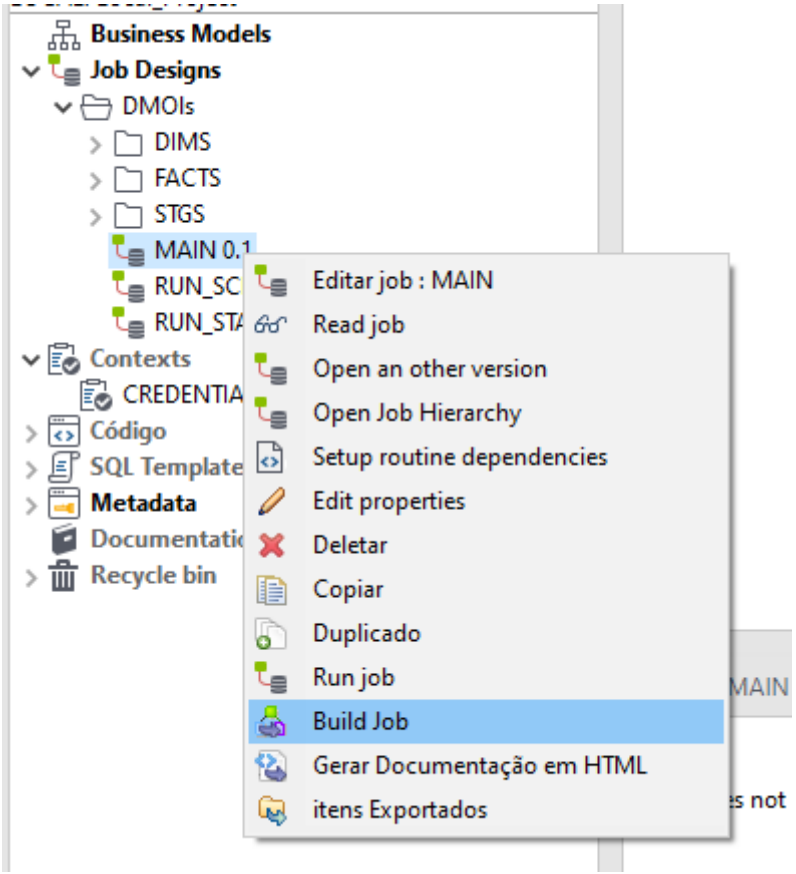

Então, irá abrir um popup para você especificar um path para salvar e clicar em finish. As demais opções são para especificar quais exportações irá fazer e quais context (credenciais) vai ser utilizada.

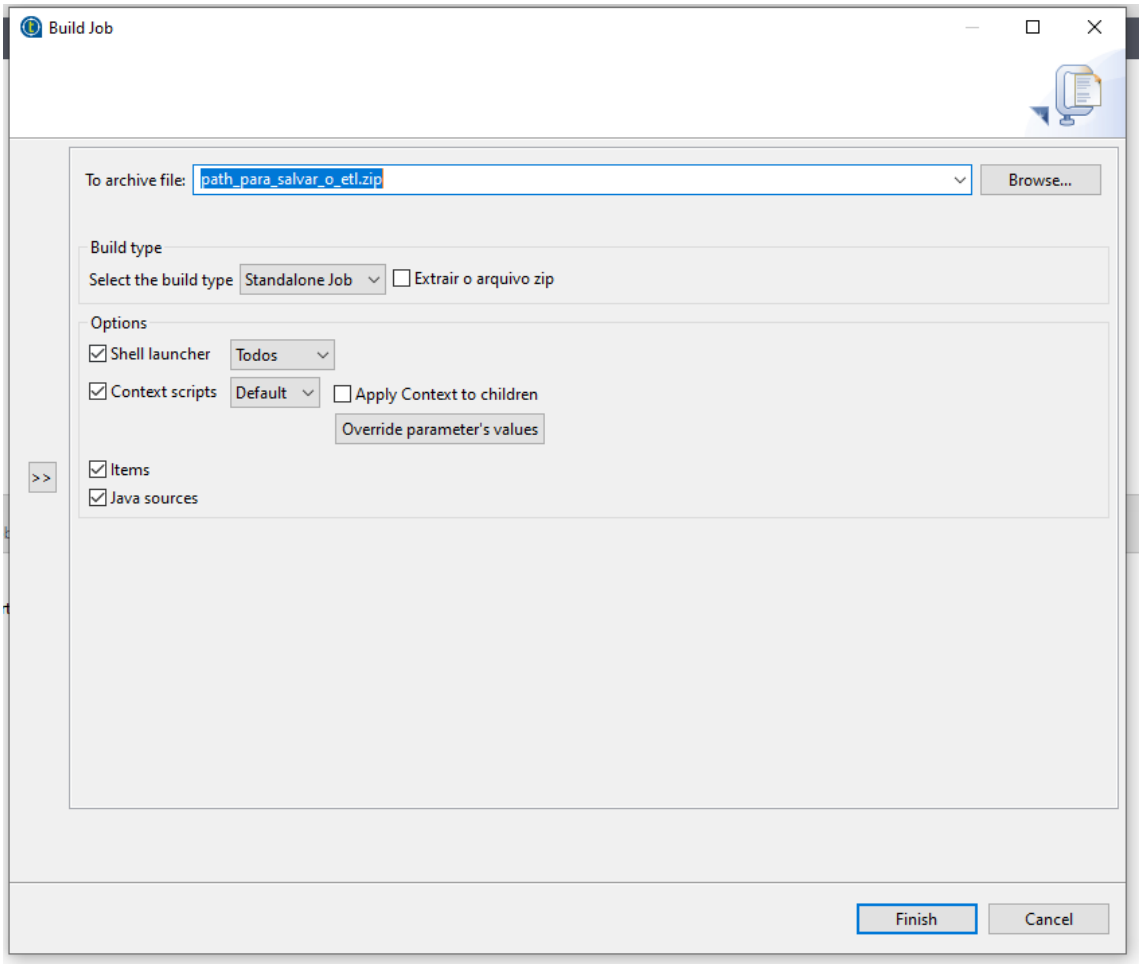

Chamei o arquivo de Main.zip. Dentro deste arquivo existem os arquivos MAIN_run.*, assim você consegue executar o job em diferentes s.o, apenas executando o script, ex: no windows pelo cmd o arquivo MAIN_run.bat e pelo powershell o arquivo MAIN_run.ps1.

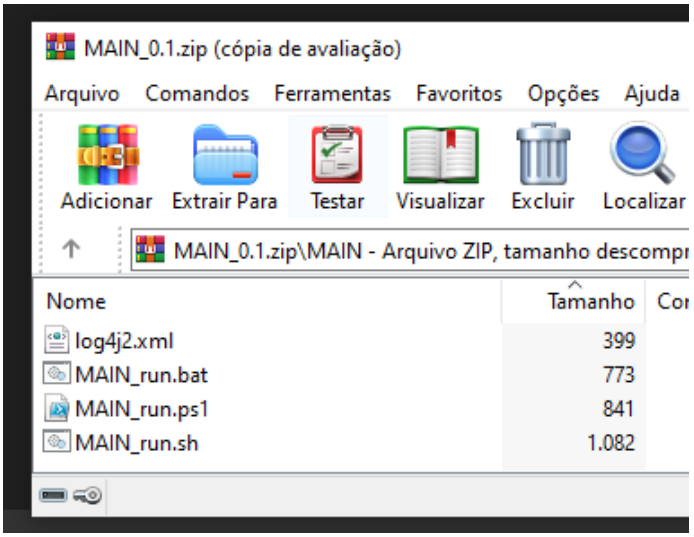

Já para a versão do Python, basta criar um script .sh ou .ps1 com as variáveis de ambiente das credenciais e a execução do script dentro de um ambiente de desenvolvimento como o do poetry ou, por exemplo, em um container com a ajuda do docker.